

Yefai: Çok Modlu Kestirimci Bakım için Yerel Yapay Zeka Tabanlı Bir Platform

Yazar Adı Soyadı

Bölüm / Program

Üniversite / Kurum

Şehir, Ülke

E-posta veya Öğrenci Numarası

Özet—Bu çalışma, üretim ortamlarında kesici takım aşınmasını izlemek, görüntü tabanlı anomali belirtilerini değerlendirmek, bakım kararlarını yedek parça riskleriyle ilişkilendirmek ve operatöre karar destek bilgisi sunmak amacıyla geliştirilen Yefai platformunu tanıtmaktadır. Sistem, çok modlu takım aşınması verisini yerel olarak işler; görüntü tabanlı anomali çıkarımı, görsel-metin ortak temsil üretimi, vektör tabanlı arama, doğal dil destekli sorgulama, bildirim otomasyonu ve sentetik yedek parça krizi simülasyonu bileşenlerini bütünlük bir mimaride birleştirir. Tasarım, ağır medya dosyalarının yerel kalmasını, ilişkisel üst verinin ve vektör temsillerinin yönetilen bir veritabanı katmanında tutulmasını ve dış bildirim kanallarının denetlenebilir bir aracı mekanizma ile tetiklenmesini esas alır. Değerlendirme bulguları, set bazlı veri ayrımının veri sızıntısını engellediğini, görüntü-anomali ve bildirim bileşenlerinin otomatik testlerle doğrulandığını, canlı dış servis gerektiren kısımların ise manuel kapılarla açıkça ayrıldığını göstermektedir.

Index Terms—kestirimci bakım, takım aşınması, görüntü anomalisi, çok modlu veri, vektör arama, yedek parça riski, bildirim otomasyonu

I. GİRİŞ

Endüstriyel üretim hatlarında takım aşınmasının geç fark edilmesi; kalite sapması, plansız duruş, üretim kaybı ve bakım maliyeti doğurur. Kestirimci bakım yaklaşımı, arıza oluşmadan önce aşınma davranışını yorumlayarak karar vericinin müdahale zamanını daha güvenilir biçimde belirlemesini amaçlar. Yefai platformu bu problemi çok modlu bir bakışla ele alır: kamera görüntüleri, sensör ölçümleri, operasyonel üst veri, stok riski ve bildirim süreçleri tek bir karar destek akışında birleştirilir.

Çalışmanın ana katkısı, görüntü temelli aşınma gözlemini bakım aksiyonuna bağlayan uçtan uca bir arka uç mimarisi sunmasıdır. Sistem yalnızca anomali skorunu üretmekle kalmaz; aşınmanın kritik eşiğe yaklaşma davranışını yorumlar, ilgili yedek parçayı sentetik envanter modeliyle ilişkilendirir, stok ve tedarikçi riskini sayısallaştırır ve uygun durumda satın alma hazırlığı ile çok kanallı uyarı akışını başlatır. Böylece bakım kararı, tekil bir model çıktısından ziyade teknik durum, operasyonel risk ve tedarik koşullarının bileşiminden türetilir.

Platformun ilk sürümü arka uç kapsamına odaklanmaktadır. Masaüstü arayüzü, canlı grafikler ve yerel bildirim kabuğu sonraki aşamalara bırakılmıştır. Buna karşılık veri altyapısı, görüntü tabanlı çıkarım, vektör temsili, sorgulama zemini, bildirim sözleşmeleri ve yedek parça simülasyonu arka uç düzeyinde ele alınmıştır. Bu ayrım, değerlendirmede tamamlanan

ve dış bağımlılığa bağlı kalan gereksinimlerin açık biçimde izlenmesini sağlar.

II. İLGİLİ ÇALIŞMALAR

Kestirimci bakım literatürü, makine sağlığını tahmin etmek için titreşim, akustik, kuvvet, sıcaklık ve görüntü gibi kaynaklardan yararlanır. Zaman serisi sinyalleri özellikle rulman, motor ve kesici takım izleme alanlarında yaygın kullanılmakla birlikte, yüzey görüntüleri aşınmanın görsel karakterini doğrudan temsil ettiği için takım aşınması problemlerinde tamamlayıcı bir kanıt sunar. Çok modlu takım aşınması veri kümeleri bu nedenle hem sensör tabanlı hem de görüntü tabanlı yöntemleri kıyaslamak için değerli bir zemin oluşturur [1].

Görüntü anomalisi alanında derin temsil çıkarımı ve yakın komşuluk tabanlı yöntemler, az sayıda normal örnekle çalışabilmeleri nedeniyle endüstriyel denetimde öne çıkmaktadır. PatchCore yaklaşımı, önceden öğrenilmiş görsel temsillerden seçilmiş bir bellek bankası oluşturarak anomalileri normal örnek uzayına uzaklık üzerinden değerlendirir [2]. Bu strateji, yoğun etiket gerektiren tam denetimli öğrenmeye kıyasla prototip ve demo sistemlerinde daha uygulanabilir bir çözüm sunar. Anomalib ise bu tür algoritmaları standartlaştırılmış eğitim ve değerlendirme akışlarıyla erişilebilir kılar [3].

Metin ve görüntüyü ortak bir temsil uzayında modelleyen çok modlu embedding yaklaşımları, doğal dil ile görsel arama arasında köprü kurar. CLIP ailesi, görüntü-metin eşleşmesini geniş ölçekli karşıt öğrenme ile temsil ederek semantik aramayı mümkün kılmıştır [4]. Çok dilli ve yerel çalışabilir embedding modelleri, endüstriyel veri gizliliği ile kullanıcı dil esnekliğini birlikte desteklediğinden bakım sistemleri için uygundur [5]. Vektör uzayı üzerinde benzerlik araması ise ilişkisel filtrelerle birleştiğinde hem semantik hem de operasyonel koşullara duyarlı hibrit sorgulama sağlar [6].

Bildirim ve otomasyon katmanında webhook tabanlı entegrasyonlar, olay üreten sistemlerle çok kanallı mesajlaşma altyapıları arasında gevşek bağılılık sağlar. Bu yaklaşım, bakım alarmı, günlük rapor ve kritik eskalasyon gibi farklı senaryoların aynı olay sözleşmesi üzerinden yönetilmesine olanak verir. Yefai bu çizgide, yapay zeka çıktısını doğrudan kullanıcıya iletmek yerine denetlenebilir tekrar deneme, yedek davranış ve kayıt mekanizmalarıyla zenginleştirilmiş bir otomasyon hattına dönüşür.

III. SİSTEM MİMARISI VE YÖNTEM

A. Genel Mimari

Yefai katmanlı bir arka uç mimarisine sahiptir. Veri hazırlama katmanı, çok modlu takım aşınması verisini ayrıştırır ve sızıntısız eğitim-test ayrımını üretir. Yapay zeka katmanı, görüntü anomalisi, aşınma tipi yorumu, görsel-metin temsili ve aşınma projeksiyonu görevlerini yürütür. Uygulama katmanı, bu çıkarımları sorgulanabilir ve olay odaklı arayüzlere dönüştürür. Karar destek katmanı ise stok, tedarikçi, satın alma ve bildirim mekanizmalarını bakım riskiyle ilişkilendirir.

YER TUTUCU — GENEL MİMARİ DİYAGRAMI

Kaynak: Yazar tarafından çizilecek mimari diyagram.
Beklenen içerik: Veri hazırlama, yapay zeka çıkarımı, vektör veritabanı, sorgulama, bildirim otomasyonu ve yedek parça riski katmanlarının akışı.

Şekil 1. Yefai platformunun kavramsal katman mimarisi.

Mimari tasarımı iki ilke belirleyicidir. Birincisi, görüntü ve sensör gibi büyük dosyaların yerel ortamda tutulmasıdır. Böylece bulut depolama maliyeti ve veri aktarım yükü azaltılır. İkincisi, üst veri ve vektör temsillerinin yönetilen bir ilişkisel veritabanı üzerinde saklanmasıdır. Bu ayırım, hem semantik aramayı hem de operasyonel filtrelemeyi desteklerken ağır medya dosyalarını sistem sınırları içinde tutar.

B. Teknoloji Seçimi

Sistem arka uç tarafında asenkron web uygulama ilkelerini izleyen bir Python mimarisi kullanır. Görüntü anomalisi için PatchCore tabanlı yöntem, çok modlu arama için ortak görsel-metin embedding modeli, semantik sorgulama için vektör uzantılı ilişkisel veritabanı ve canlı çıkarım için yerel konteyner tabanlı model yürütme yaklaşımı benimsenmiştir. Tablo I kullanılan bileşenleri kavramsal rollerine göre özetlemektedir.

Tablo I
TEMEL TEKNOLOJİ BİLEŞENLERİ VE TASARIM GEREKÇELERİ.

Bileşen	Rol	Gerekçe
Web uygulama çatısı	Arka uç arayüzleri	Tip denetimli veri sözleşmeleri, otomatik dokümantasyon ve asenkron yürütme
Görüntü anomalisi	Aşınma sinyali çıkarımı	Az örnekli normal temsilden sapma ölçümü [2]
Çok modlu embedding	Görsel-metin araması	Türkçe dahil çok dilli semantik sorgu ve yerel çalışma [5]
Vektör veritabanı	Hibrit sorgulama	Vektör benzerliği ile ilişkisel filtrelerin birleşimi [6]
Konteyner tabanlı çıkarım	Yerel model servisleme	Bulut bağımlılığını azaltan tekrar üretilebilir yürütme ortamı
Webhook otomasyonu	Uyarı ve rapor akışı	Çok kanallı bildirimleri gevşek bağlı bir olay hatına dönüştürme

C. Veri Yönetim Stratejisi

Veri yönetimi, ağır medya ve hafif sorgu verisi ayrımına dayanır. Görüntüler ve sensör ölçümleri yerel dosya alanında tutulurken; set kimliği, zaman damgası, aşınma seviyesi, aşınma türü, anomali skoru, vektör temsili ve bildirim kayıtları ilişkisel depolama katmanında yönetilir. Bu strateji, veri hacmini sınırlı tutarken model çıktılarının denetlenebilirliğini korur.

Veri ayrımı set düzeyinde yapılmıştır; aynı üretim seti hem eğitim hem test bölmesine dağıtılmaz. Bu karar, benzer zaman ve operasyon koşullarından gelen örneklerin iki bölme arasında sızmasını önler. Veri kalite raporlarına göre 17 üretim setinden 1803 etiketli görüntü elde edilmiş, 1292 görüntü eğitim ve 511 görüntü test bölümünde tutulmuştur. Aşınma dağılımı 0–300 mikrometre aralığındadır; yüksek aşınma eşiği üzerindeki örnek oranı yaklaşık yüzde 7.9 olarak gözlenmiştir.

IV. GEREKSİNİM KAPSAMI

Gereksinimler arka uç odaklı ilk sürüm ve sonraki masaüstü arayüz aşaması olarak ayrılmıştır. İlk sürümde veri seti yönetimi, görüntü tabanlı çıkarım, embedding, vektör arama, RAG arayüzü için API zemini, bildirim sözleşmeleri ve yedek parça krizi simülasyonu öne çıkar. Canlı grafikler, masaüstü kabuğu ve son kullanıcı panelleri sonraki sürüm kapsamına bırakılmıştır. Bu ayırım, sistemin araştırma ve prototip hedefleriyle uygulanabilir teslimat sınırlarını uyumlu hale getirir.

Tablo II
FONKSİYONEL GEREKSİNİM GRUPLARININ KAVRAMSAL DURUM ÖZETİ.

Gereksinim grubu	Durum	Açıklama
Veri seti yönetimi	Tamamlandı	Ayrıştırma, kalite raporu, set bazlı ayırım ve sentetik yedek parça verisi üretildi.
Görüntü çıkarımı	Kısmi/Tamamlandı	Eğitim ve embedding hattı uygulanmış; canlı yerel çıkarım dış kapıya bağlıdır.
Gerçek zamanlı akış	Sonraki aşama	Kullanıcı arayüzü ve canlı gösterim kapsamına bırakılmıştır.
RAG sorgulama	API zemini	Embedding ve hibrit arama bileşenleri doğal dil sorgulama için temel oluşturur.
Bildirim otomasyonu	Mock yeşil	Payload, tekrar deneme, yedek davranış ve kayıt sözleşmeleri doğrulanmıştır.
Masaüstü uygulama	Sonraki aşama	Yerel kabuk ve canlı kullanıcı deneyimi arka uç sonrası ele alınacaktır.
Veritabanı ve embedding	Tamamlandı	Üst veri ve vektör temsilleri için yönetilen ilişkisel model planlanmıştır.
Yedek parça krizi	Tamamlandı	Sentetik katalog, risk skoru, satın alma hazırlığı ve alternatif tedarikçi mantığı oluşturulmuştur.

V. GÖRÜNTÜ TABANLI ANOMALİ VE AŞINMA YORUMU

Görüntü tabanlı çıkarımın amacı, kesici takım yüzeyinde normal davranıştan sapmayı ölçmek ve bakım kararı için nicel bir skor üretmektir. PatchCore temelli yaklaşımda normal

veya düşük aşınmalı görüntülerden temsil belleği oluşturulur. Test aşamasında yeni görüntülerin temsilleri bu belleğe göre uzaklık üzerinden değerlendirilir. Yüksek uzaklık, yüzeyde alışılmadık aşınma örüntüsü bulunduğunu gösteren bir anomali sinyali olarak ele alınır.

Algorithm 1 Görüntü Tabanlı Anomali Değerlendirme Akışı

- 1: Çok modlu veri kümesini set düzeyinde eğitim ve test bölmelerine ayır
- 2: Normal veya düşük aşınmalı eğitim görüntülerinden temsil belleği oluştur
- 3: Yeni görüntüyü standart ön işleme adımlarından geçir
- 4: Görüntü temsili normal temsil belleğiyle karşılaştır
- 5: Uzaklık ölçüsünden anomali skorunu hesapla
- 6: **if** anomali skoru karar eşiğini aşarsa **then**
- 7: Görüntüyü bakım riski adayı olarak işaretle
- 8: Aşınma türü ve operasyonel üst veriyle açıklama üret
- 9: **else**
- 10: Görüntüyü normal izleme akışında tut
- 11: **end if**
- 12: **return** Anomali skoru, risk etiketi ve açıklayıcı üst veri

Aşınma türü yorumu, bakım kararının açıklanabilirliğini artırır. Flank aşınması, yapışmalı aşınma ve bileşik aşınma gibi türler farklı operasyonel nedenlere işaret edebilir. Bu nedenle sistem, yalnızca anomali varlığını değil, mümkün olduğunda aşınma karakterini de karar destek çıktısına ekler. Sensör ölçümleri ilk sürümde anomali kararının ana girdisi değildir; ancak görsel kararın zaman ve operasyon bağlamını zenginleştiren tamamlayıcı veri olarak tutulur.

YER TUTUCU — GÖRÜNTÜ ANOMALİ SONUCU

Kaynak: Test görüntüsü üzerinde çalıştırılan çıkarım ekranı veya rapor çıktısı.
Beklenen içerik: Normal ve anomali adaylarının skor, aşınma seviyesi ve aşınma türüyle karşılaştırılması.

Şekil 2. Görüntü tabanlı anomali değerlendirme sonucunun örnek gösterimi.

VI. ÇOK MODLU ARAMA VE RAG DESTEKLİ SORGULAMA

Bakım operatörü çoğu zaman teknik veriyi doğal dilde sorgulamak ister. Örneğin belirli bir üretim setindeki en yüksek aşınma örneğini, belirli bir aşınma türüne sahip görüntüleri veya stok riskiyle ilişkili parça kayıtlarını aramak isteyebilir. Bu gereksinim için sistem, görüntü ve metin temsillerini ortak bir vektör uzayında ele alır. Kullanıcı sorusu embedding modelinden geçirilir; benzer görsel ve üst veri kayıtları vektör benzerliği ile bulunur; ardından set, zaman, aşınma türü ve risk seviyesi gibi ilişkisel filtrelerle sonuçlar daraltılır.

RAG mekanizması yalnızca cevap üretme katmanı değildir; aynı zamanda bakım kararının dayandığı bağlamı seçen bir bilgi erişim bileşenidir. Modelin üretici yanıtı, seçilen bağlamla sınırlandırılarak halüsinasyon riski azaltılır. İlk sürümde API zemini ve hibrit arama sözleşmesi önceliklidir;

tam etkileşimli sohbet deneyimi kullanıcı arayüzü aşamasında olgunlaştırılacaktır.

Algorithm 2 Hibrit Görsel-Metin Sorgulama Akışı

- 1: Kullanıcı sorusunu çok modlu temsil uzayına dönüştür
- 2: Vektör benzerliğiyle aday kayıtları getir
- 3: Operasyonel filtreleri uygula
- 4: Görüntü, aşınma, zaman ve risk bağlamını birleştir
- 5: Yanıt üretici modele yalnızca seçilmiş bağlamı ver
- 6: Sonucu tablo, özet ve görsel referans bilgisiyle döndür
- 7: **return** Doğal dil yanıtı ve denetlenebilir bağlam özeti

VII. YEDEK PARÇA KRIZI VE BİLDİRİM OTOMASYONU

Anomali tespiti tek başına bakım kararını tamamlamaz; ilgili parçanın stokta bulunup bulunmadığı, tedarik süresi, tedarikçi güvenilirliği ve aşınmanın kritik eşiğe yaklaşma hızı da kararı etkiler. Bu nedenle Yefai, görüntü veya tahmin çıktısını sentetik yedek parça katmanıyla ilişkilendirir. İlk sürümde gerçek envanter sistemi bulunmadığından, 40 yedek parça, 10 tedarikçi, stok anlık görünümü, talep kayıtları ve satın alma hazırlığı içeren sentetik bir simülasyon katmanı oluşturulmuştur. Bu katman gerçek satın alma işlemi yapmaz; yalnızca karar destek ve demo akışı sağlar.

Kriz skoru stok açığı, tedarik süresi baskısı, parça kritiklik sınıfı, tedarikçi riski ve anomali şiddetinin ağırlıklı bileşiminden hesaplanır. Skor aralığı 0 ile 100 arasındadır ve sonuç normal izleme, dikkat, riskli veya kriz seviyesine dönüştürülür. Riskli veya kriz durumunda sistem satın alma hazırlığı üretir ve alternatif tedarikçi arar. Tablo III kriz hesaplamasında kullanılan ana değişkenleri özetler.

Tablo III
YEDEK PARÇA KRİZ SKORU BİLEŞENLERİ.

Bileşen	Ağırlık	Bakım kararındaki anlamı
Stok açığı	0.30	Eldeki miktarın minimum güvenli seviyeyi karşılayamaması
Tedarik süresi baskısı	0.25	Parçanın kritik zamana yeti-meme olasılığı
Kritiklik sınıfı	0.20	Parçanın üretim sürekliliği üzerindeki etkisi
Tedarikçi riski	0.15	Birincil tedarikçinin güvenilirlik ve süre riski
Anomali şiddeti	0.10	Teknik aşınma sinyalinin operasyonel önemi

Algorithm 3 Anomaliden Kriz ve Bildirim Aksiyonuna Geçiş

- 1: Anomali veya aşınma tahmin sonucunu al
- 2: İlgili yedek parça ailesini ve stok durumunu belirle
- 3: Stok açığı, tedarik süresi, kritiklik ve tedarikçi riskini hesapla
- 4: Ağırlıklı kriz skorunu üret
- 5: **if** risk seviyesi yüksek ise **then**
- 6: Satın alma hazırlığı oluştur
- 7: Daha kısa sürede karşılayabilecek alternatif tedarikçileri sırala
- 8: Bildirim olayını oluştur ve gönderim kuyruğuna al
- 9: **else**
- 10: Durumu izleme kaydı olarak sakla
- 11: **end if**
- 12: **return** Kriz skoru, önerilen aksiyon, satın alma özeti ve bildirim durumu

Bildirim otomasyonu, olayların dış kanallara güvenilir biçimde iletilmesi için tekrar deneme ve yedek davranış ilkelerini kullanır. Dış servis kullanılmadığında olay kaydı korunur ve yerel yedek davranış devreye alınır. Bu tasarım, canlı Telegram, e-posta ve kısa mesaj gönderimlerinin dış hesap ve webhook kapılarına bağlı olduğunu açık biçimde ayırır; sistem bu kapılar tamamlanmadan canlı gönderimi tamamlanmış saymaz.

YER TUTUCU — KRİZ İŞ AKIŞI SONUCU

Kaynak: Yedek parça krizi simülasyon ekranı veya API çıktısından hazırlanacak görsel.

Beklenen içerik: Kriz skoru, risk seviyesi, satın alma hazırlığı, alternatif tedarikçiler ve bildirim durumunun tek akışta gösterimi.

Şekil 3. Yedek parça krizi ve bildirim otomasyonu çıktısının örnek gösterimi.

VIII. AŞINMA PROJEKSİYONU

Aşınma projeksiyonu, anomali skorunu bakım zamanlamasına dönüştürmeyi amaçlar. Sistem, mevcut aşınma tahmini ile zamana bağlı aşınma hızını kullanarak kritik eşiğe kalan süreyi hesaplar. Kritik eşik 200 mikrometre olarak ele alınır. Aşınma hızı çok düşük olduğunda sonuç üst sınırla sınırlandırılır; yeterli veri noktası ve regresyon kalitesine göre güven seviyesi atanır.

Projeksiyon çıktısı, yedek parça krizi hesabındaki tedarik süresi baskısını zenginleştirir. Örneğin parça tedarik süresi kritik eşiğe kalan süreden uzunsa, stok veya tedarikçi riski daha yüksek değerlendirilir. Böylece teknik aşınma sinyali, yalnızca görsel anomali değil, tedarik kararı için zaman baskısı olarak da kullanılır.

Tablo IV

AŞINMA PROJEKSİYONUNDA KULLANILAN TEMEL KARAR DEĞİŞKENLERİ.

Değişken	Karar etkisi
Mevcut aşınma seviyesi	Kritik eşiğe olan teknik mesafeyi belirler.
Aşınma hızı	Kritik eşiğe kalan süreyi hesaplamak için kullanılır.
Regresyon uyumu	Tahmin güven düzeyini etkiler.
Veri noktası sayısı	Yetersiz veri durumunu ayırt eder.
Tedarik süresi	Kriz skorunda zaman baskısını artırır veya azaltır.

IX. DEĞERLENDİRME

Değerlendirme üç düzeyde yapılmıştır: veri kalitesi, bileşen davranışı ve entegrasyon sözleşmesi. Veri kalitesi düzeyinde 17 set ve 1803 etiketli görüntü ayrıştırılmış, eğitim-test ayrımı set bazında uygulanmış ve sızıntıyı önleyen bölme korunmuştur. Sensör verisinin her sette beklenen kanalları kapsadığı; zaman eşlemesinin ise veri kümesi kaynaklı farklar nedeniyle kayıt ve kontrol gerektirdiği belirlenmiştir.

Bileşen davranışı düzeyinde görüntü anomalisi, embedding, yerel çıkarım sözleşmesi, yedek parça krizi ve bildirim akışları otomatik testlerle ele alınmıştır. Yerel görüntü çıkarımı tarafında canlı konteyner ve model dağıtımı dış kimlik bilgileri ile model artefaktına bağlı olduğu için mock ve canlı doğrulama ayrımı yapılmıştır. Bildirim tarafında payload üretimi, tekrar deneme, yedek davranış, kriz skoru, satın alma hazırlığı ve alternatif tedarikçi önerisi test edilmiştir.

Tablo V
DEĞERLENDİRME BULGULARININ ÖZETİ.

Alan	Sonuç	Yorum
Veri ayrımı	Başarılı	Set bazlı bölümlenme ile sızıntı riski azaltıldı.
Etiketli görüntüler	1803 kayıt	Eğitim ve test için yeterli prototip tabanı oluşturuldu.
Test bölümü	511 kayıt	Canlı demo ve çıkarım değerlendirmesi için ayrıldı.
Yüksek aşınma oranı	Yaklaşık %7.9	Sınıf dengesizliği karar eşiği seçimini önemli kılar.
NovaVision sözleşmesi	Mock yeşil	Canlı doğrulama dış kurulum kapısına bağlıdır.
Bildirim ve kriz	Mock yeşil	Tek akışta tahmin, kriz, satın alma ve bildirim çıktısı üretildi.
Otomatik testler	Geçti	Arka uç kalite kapıları mevcut kapsam için yeşildir.

YER TUTUCU — DEĞERLENDİRME ÖZETİ

Kaynak: Veri kalite raporu ve test sonuçlarından hazırlanacak özet görsel.

Beklenen içerik: Veri dağılımı, eğitim-test bölmesi, aşınma türleri ve doğrulama durumlarının tek panelde gösterimi.

Şekil 4. Veri ve doğrulama sonuçlarının özet görünümü.

Dış bağımlılıklar değerlendirmede özellikle ayrıştırılmıştır. Yerel model konteyneri için kimlik bilgisi, canlı model ar-

tefaktı ve kurulum doğrulaması gereklidir. Çok kanallı bildirim için gerçek hesap ve webhook adresleri insan tarafından sağlanmalıdır. Bu nedenle sistem, mock sözleşmeleri yeşil olsa bile canlı dış kanal başarısını tamamlanmış saymaz. Bu yaklaşım, akademik raporlama açısından iddiaların kanıt kapsamıyla uyumlu kalmasını sağlar.

X. TEHDITLER VE SINIRLILIKLAR

İlk sınırlılık, sensör verisinin anomali kararında ana sinyal olarak kullanılmamasıdır. Sensör kanalları saklanmakta ve bağlam sağlamaktadır; ancak ilk sürümde görüntü temelli anomali daha baskın tasarım kararıdır. İkinci sınırlılık, yedek parça katmanının gerçek ERP veya bakım yönetimi sistemiyle bağlı olmamasıdır. Sentetik katalog ve tedarikçi verisi karar destek akışını test etmek için yeterli olsa da gerçek operasyonel veriyle kalibrasyon gerektirir.

Üçüncü sınırlılık, canlı bildirim ve yerel model dağıtımının manuel kapılara bağlı olmasıdır. Dış hesaplar ve yerel kurulum tamamlanmadan canlı Telegram, e-posta, kısa mesaj veya konteyner çıkarımı başarısı iddia edilmemelidir. Son olarak, son kullanıcı arayüzü ve masaüstü deneyimi sonraki aşamaya bırakıldığı için mevcut değerlendirme arka uç davranışlarına odaklanmaktadır.

XI. SONUÇ VE GELECEK ÇALIŞMALAR

Bu rapor, Yefai platformunun çok modlu kestirimci bakım için geliştirdiği arka uç mimarisini IEEE formatında özetlemiştir. Sistem; MATWI verisi üzerinde sızıntısız veri ayrımı, görüntü tabanlı anomali çıkarımı, çok modlu embedding, hibrit arama, RAG destekli sorgu zemini, yedek parça krizi simülasyonu ve bildirim otomasyonunu birleştiren bütünleşik bir yapı sunmaktadır. Mevcut durumda veri altyapısı, yedek parça simülasyonu ve arka uç bildirim sözleşmeleri güçlü biçimde doğrulanmış; canlı dış servisler ve kullanıcı arayüzü ise açık biçimde sonraki iş paketlerine ayrılmıştır.

Gelecek çalışmalar dört yönde ilerleyebilir. İlk olarak, canlı yerel model dağıtımı tamamlanmalı ve gerçek görüntüler üzerinde uçtan uca çıkarım ölçülmelidir. İkinci olarak, RAG bileşeni kullanıcı arayüzüyle birleştirilerek doğal dil sorguları görsel ve tablo çıktılarıyla sunulmalıdır. Üçüncü olarak, masaüstü kabuğu ve canlı grafikler tamamlanarak operatör deneyimi test edilmelidir. Dördüncü olarak, sentetik yedek parça katmanı gerçek ERP, MRO veya CMMS sistemleriyle değiştirilmeli ve kriz skoru gerçek operasyonel verilerle kalibre edilmelidir.

TEŞEKKÜR

Bu rapordaki yazar, kurum ve ders bilgileri yer tutucu olarak bırakılmıştır. Nihai teslim öncesinde ilgili akademik veya kurumsal bilgilerle güncellenmelidir.

KAYNAKLAR

- [1] M. Mazzoleni, L. Scandella *et al.*, “Multi-modal automatic tool wear inspection dataset,” Public research dataset for tool wear inspection, 2023, accessed: 2026-05-17.
- [2] K. Roth, L. Pemula, J. Zepeda, B. Scholkopf, T. Brox, and P. Gehler, “Towards total recall in industrial anomaly detection,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022, pp. 14 318–14 328.

- [3] OpenVINO Toolkit Contributors, “Anomalib: A deep learning library for anomaly detection,” <https://github.com/openvinotoolkit/anomalib>, 2024, accessed: 2026-05-17.
- [4] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever, “Learning transferable visual models from natural language supervision,” in *Proceedings of the International Conference on Machine Learning*, 2021, pp. 8748–8763.
- [5] Jina AI, “Jina clip v2: Multilingual multimodal embeddings,” <https://jina.ai/embeddings/>, 2024, accessed: 2026-05-17.
- [6] pgvector Contributors, “pgvector: Open-source vector similarity search for postgresql,” <https://github.com/pgvector/pgvector>, 2024, accessed: 2026-05-17.